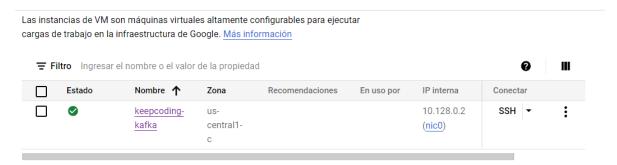
# Proyecto de Big Data Processing

La idea principal de proyecto es el manejo y procesamiento de datos, para ello se usarán varia tecnología que a continuación describiremos:

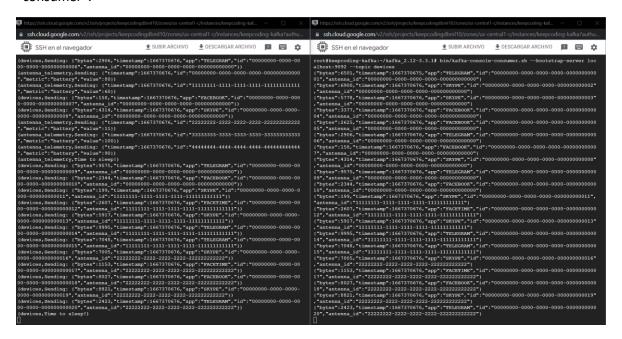
## Kafka y Docker

Como parte inicial se generó una máquina virtual en Google Cloud Computer (GCC), tal como se muestra a continuación



Posteriormente de verifico que tuviera acceso libre mediante una regla de firewall, para permitir las conexiones entrantes, debido a que nos conectaremos a ella.

Se instalo Docker y Kafka, para la generación de mensajes en tópicos, para poder consumirlos de forma local, a través de la IP pública. se generó una prueba de donde la pantalla de la izquierda es una consola de la instancia ejecutando un "producer" mediante un Docker, y de la segunda pantalla es una consola la misma instancia (VM), pero ejecutando un consumido de mensajes "consumer".



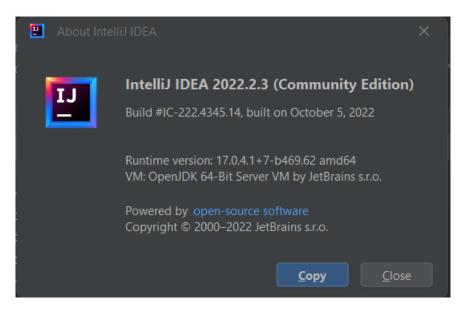
#### SQL

En la misma plataforma de Google, se usara el servicio de servidor SQL, es decir Google Cloud SQL, y en este servicio se seleccionará una base de datos de PostgreSQL, en ella almacenaremos los datos que enriquecerán, a los producidos por Kafka.



# Programación

Como IDE de programación se uso IntelliJ IDEA en la versión 2022.2.3, de edición "Community Edition"



#### Provisioner

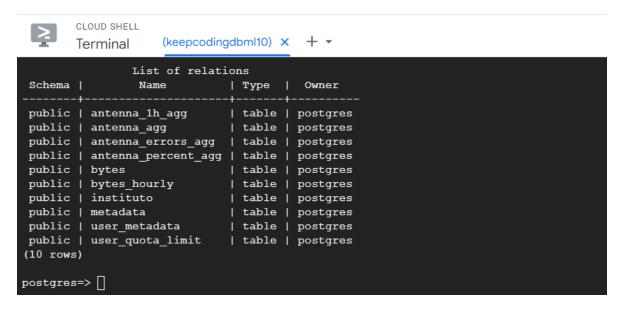
En este código es para la generación de tablas y llenado de algunas de ella, en la nube, decir en el Storage Seleccionado, en nuestro caso el servicio proporcionado por Google Cloud SQL.



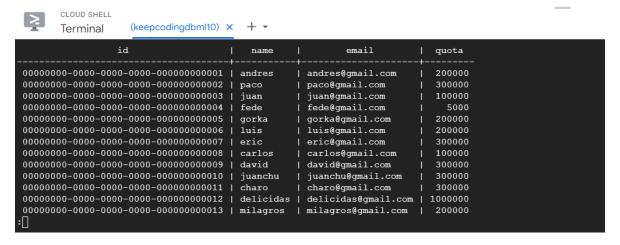
La ejecución de este código nos genera nuestras tablas:

- user\_metadata: que contendrá lo información del "user", con información de: id, name, email y quota.
- Bytes: Contendrá las métricas de las antenas, que guardará los totales de bytes recibidos por antena, por usuario y aplicación.
- bytes\_hourly: métricas de recibidos y transmitidos, por "antenna", "user" y "App"
- user\_quota\_limit: contendrá el total de usuario que sobrepasaron su límite "quota"

El resultado se muestra a continuación:



Así mismo este código llena la tabla de "user\_metadata":



Sus argumentos de entrada son:

- Conexión a Google Cloud SQL:
  - Driver: "org.postgresql.Driver"
  - o url: "jdbc:postgresql://34.171.245.100:5432/postgres"
  - o username: "postgres"
  - o password: "keepcoding"

# Streaming (Speed Layer)

Los códigos de esta capa, se conectan a kafka y postgres para obtener información

Las funciones definidas y su orden ejecución van de la siguiente forma:

 readFromKafka: lee los mensajes desde Kafka, del tópico "devices", la conexión se realiza mediante la conexión a la Maquina Virtual mediante readFromKafka("146.148.62.187:9092", "devices"), donde ponemos la IP del servidor de kafaka y el tópico del que consumirá los mensajes. En un principio el Batch no ha llenado, por ello nos muestra solo la estructura:

Finalmente se empieza ha llenar la estructura con los mensajes de Kafka:

Estos datos son almacenados en la variable "kafkaDF", que vienen con un formato de JSON, por lo que lo deberemos procesar.

2. **parserJsonData**: parsea la variable "kafkaDF", es decir pasa de un formato JSON a un DataFrame, el resultado lo almacenamos en la variable "parsedDF".

3. writeToStorage: este procedimiento realiza el guardado de batch obtenido de Kafka, el storage que se usa es de tipo local, este de realiza de la siguiente forma: writeToStorage(parsedDF, "/tmp/antenna\_parquet/"), en donde como parámetros de entrada de la función "writeToStorage", son el dataFrame parseado de Kafka, y la tuta donde se realizara el guardado. El guardado será particionado, por año, mes, día y hora, apartir de fecha que dispone el campo de "timestamp". El resultado es el siguiente:

Este equipo $\rightarrow$ OS (C:) $\rightarrow$ tmp $\rightarrow$ antenna_parquet $\rightarrow$ data $\rightarrow$ year=2022 $\rightarrow$ month=10 $\rightarrow$ day=31 $\rightarrow$ hour=2			
Nombre	Fecha de modificación	Tipo	Tamaño
part-00000-438cb5f6-d97a-436e-86cc-a	31/10/2022 02:55 a. m.	Archivo CRC	1 KB
part-00000-612e742e-510c-4058-9024-6	31/10/2022 02:58 a. m.	Archivo CRC	1 KB
part-00000-8934d9e6-b47b-4ee8-8f4c-8	31/10/2022 02:54 a. m.	Archivo CRC	1 KB
	31/10/2022 02:59 a. m.	Archivo CRC	1 KB
part-00000-c09d16d1-6ecb-461e-9c60	31/10/2022 02:56 a.m.	Archivo CRC	1 KB
part-00000-ece13a5e-4376-43db-b14f-8	31/10/2022 02:57 a. m.	Archivo CRC	1 KB
part-00000-438cb5f6-d97a-436e-86cc-af	31/10/2022 02:55 a. m.	Archivo PARQUET	2 KB
part-00000-612e742e-510c-4058-9024-6	31/10/2022 02:58 a. m.	Archivo PARQUET	2 KB
part-00000-8934d9e6-b47b-4ee8-8f4c-8	31/10/2022 02:54 a. m.	Archivo PARQUET	3 KB
part-00000-acef1c99-d5a6-4179-ac84-e	31/10/2022 02:59 a. m.	Archivo PARQUET	2 KB
part-00000-c09d16d1-6ecb-461e-9c60-3	31/10/2022 02:56 a.m.	Archivo PARQUET	2 KB
part-00000-ece13a5e-4376-43db-b14f-8	31/10/2022 02:57 a.m.	Archivo PARQUET	2 KB

Estos archivos en formato Parquet, se usarán para la etapa de Batch, y dejar de usar el

4. **readAntennaMetadata**: realiza la obtención de los datos contenidos en la tabla "user\_metadata" que se encuentra en Google Cloud SQL, realiza la conexión mediante los datos de :

- o Driver: "org.postgresql.Driver"
- o url: "jdbc:postgresql://34.171.245.100:5432/postgres"
- o username: "postgres"
- o password: "keepcoding"

Una vez obtenidos los datos, estos son almacenados en la variable "metadaDF".

5. enrichAntennaWithMetadata: en este procedimiento unimos los dataframes que obtuvimos de Kafka (parseDF) y el que obtuvimos de postgres (metadaDF), esto se realiza mediante join con el identificador en común para ambos dataFrame, en este caso el "id", Finamente el resultado lo almacenamos en la variable "enrichDF", que contiene la información como se muestra en la siguiente imagen:

- 6. **computeBytes**: Este procedimiento realiza el cálculo de las métricas de consumo de bytes por:
  - Antenna: total de bytes por antena, estos datos se guardan en dataframe "aggBytesAntenna"

 User: total de bytes por usuario, estos datos se guardan en dataframe "aggBytesUser"

 App: total de bytes por aplicación, estos datos se guardan en dataframe "aggBytesApp"

7. **writeToJdbc**: Este procedimiento realiza el guardado de los datos de los frames generados del cálculo de bytes (aggBytesAntenna, aggBytesUser y aggBytesApp), en la tabla llamada "bytes" que se encuentra en Google Cloud SQL, conecion mediante "JDBC". El guardado se realiza mediante seq[Futures], para escribir los 3 dataframes en paralelo en la misma tabla.

\*Nota: no sé, porque no guarda la información si se esta bien en los dataframes.

## Batch Layer

Como se había mencionado anteriormente, lo que se guarda en el storage local, que son archivos parquet. El procedimiento es el siguiente:

- 1. readFromStorage: Lectura de archivos parquet desde el storage local.
- 2. **readAntennaMetadata**: Al igual que el Speed Layer, obtenemos los metadatos del usuario desde Google Cloud SQL.
- 3. **enrichAntennaWithMetadata**: Unimos los dos dataframes el que obtuvimos del storage local y el de PostgreSQL. La unión se realiza mediante el join, con el campo "id".
- 4. **computeBytes**: se calculan la métrica de total de bytes, como se realizo en el Speed Layer, pero con una ventana de batch de 1 hora, el dataframe generado se llama "aggByte".

```
timestamp| id|value| type|

total_bytes|

|2022-11-02 01:01:30|0000000-0000-000...|18172|user_total_bytes|

|2022-11-02 01:01:30|0000000-0000-000...| 5662|user_total_bytes|

|2022-11-02 01:01:30|00000000-0000...|18506|user_total_bytes|

|2022-11-02 01:01:30|00000000-0000...|14114|user_total_bytes|

|2022-11-02 01:01:30|0000000-0000...|10774|user_total_bytes|
```

5. **computeBytesUserQuotaLimit**: se calcula la métrica si el usuario sobrepaso su Quota de bytes.

```
+----+
| usage | quota | timestamp |
+----+
| 17838 | 20000000 | 2022-11-02 13:01:00 |
| 2188 | 400000 | 2022-11-02 13:01:00 |
| 19556 | 400000 | 2022-11-02 13:01:00 |
| 15608 | 400000 | 2022-11-02 13:01:00 |
| 10732 | 400000 | 2022-11-02 13:01:00 |
| 14248 | 2000000 | 2022-11-02 13:01:00 |
```

6. **writeToJdbc**: En este procedimiento se realiza el guardado de los data frames en sus respectivas tablas que están contenidas en Google Cloud SQL.